

Reporte analítico CRISP-DM

SDOH Digital Twin · Motor Python/Streamlit · Emitido 28/09/2026 21:24 · Fuente: PostGIS · CDC PLACES (data.cdc.gov, cwsq-ngmh) cargado por el ETL · Tracts: 1632 · Objetivo: Salud autorreportada regular o mala (%) · Modelo seleccionado: Regresión Logística

Cada gráfico y tabla se acompaña de dos bloques: **Cómo se lee** (explicabilidad: qué método se usó y cómo interpretar la figura) e **Interpretación** (lectura de los resultados obtenidos con estos datos). Cuando se generó, se añade una **interpretación asistida por IA** (LangChain/LangFlow), que debe contrastarse con los números.

II. Comprensión de los datos (carga y EDA)

1. Vista previa del dataset

geoid	name	pct_no_health_insurance	pct_food_insecurity	pct_food_stamps	pct_housing_insecurity	pct_utility_shutoff	pct_no_transportation
17031010100	17031010100	10.9	24.7	23.6	20.5	13.1	12.2
17031010201	17031010201	17.1	34.6	33.9	27.2	17.6	16.3
17031010202	17031010202	11.9	21.8	19.9	17.9	11.1	10.6
17031010300	17031010300	9.9	18.2	16.1	15.3	9.3	9
17031010400	17031010400	8.4	17.7	15.3	14.7	8.9	9.6
17031010501	17031010501	7.3	14.3	12.3	13	8.1	7.9
17031010502	17031010502	7.8	14.8	12.1	12.9	7.6	8.3
17031010503	17031010503	11.1	26.6	26.5	17.1	11.7	13.7
17031010600	17031010600	8.8	15.6	13	13.7	8	8.2
17031010701	17031010701	11.3	18.4	15.3	16	9.2	9
17031010702	17031010702	16.2	28.8	26.5	23.1	14.1	13.8
17031020100	17031020100	13.6	25	21.7	20	11.7	11.5
17031020200	17031020200	8.3	12.7	9	10.6	5.5	6.2
17031020301	17031020301	6.5	11.6	9.7	8.8	5.4	6
17031020302	17031020302	10.1	17.9	15.7	13.8	8.5	8.7

geoid	pct_lack_social_support	pct_loneliness	pct_routine_checkup	pct_cholesterol_screening	pct_smoking	pct_inactivity	pct_binge_drinking
17031010100	28.6	35.8	77.5	86.5	13.7	24.2	18.2
17031010201	31.1	37.4	75.5	83.5	17.3	30.6	17.6
17031010202	26.8	33.7	77.3	87.3	12.6	23.8	18.3
17031010300	26.1	33.5	78.2	88.5	11.2	22	18.4
17031010400	25.5	36.6	73.7	83.5	10.7	18.9	21.7
17031010501	23.9	33.4	75.5	87	8.8	16.8	21.7
17031010502	24.6	35.6	73.4	84.3	8.7	16.2	22.9
17031010503	26	36.9	77.1	81.2	13.1	28	16.6
17031010600	25	34.3	74.5	86.1	9.8	17.8	22
17031010701	26.1	33.5	76.3	88	10.8	20.7	19.9
17031010702	29	36.4	73.8	83.3	14.5	26.5	19.7
17031020100	30	36.2	77.7	87.1	13	26.7	16.8
17031020200	26	33.5	77.6	89.2	8.9	18.9	18.6
17031020301	21.8	30.6	80.4	90	8.9	20.4	16.4
17031020302	24.6	32.3	78.5	88.3	11.1	23.4	17.1

geoid	pct_fair_poor_health	pct_diabetes	pct_obesity	pct_high_bp	pct_chd	pct_depression	pct_mental_distress
17031010100	21.4	12.4	35.7	32.6	5	20.3	17.3
17031010201	27.4	13.9	38.4	33.1	5.4	20.6	18.9
17031010202	20.8	12.6	33.9	32.6	5.5	19.2	15.5
17031010300	18.7	11.9	32	32.2	5.5	19.2	15
17031010400	15.5	7.6	28.9	22.5	3.3	23.5	18.4
17031010501	13.9	8.2	29.8	25.3	3.6	20.4	15.3
17031010502	13.5	6.8	27.5	21.2	2.9	21.7	16.5
17031010503	24.4	14.7	30.4	33.2	7.4	22.9	18.8
17031010600	15	8.2	29.3	24.4	3.6	20.8	15.8
17031010701	17.7	10.3	31.6	28	4.2	18.9	14.8
17031010702	23.3	11.4	35.1	28.1	4.4	20.5	17.8
17031020100	22.3	13.1	33.1	32.6	5.3	18.4	16
17031020200	14.7	9.8	25.2	27.4	4.5	17.8	13.3
17031020301	16.1	11.5	26.1	33.1	6.7	18.9	13
17031020302	19.4	12.6	30.4	32.9	6.2	19.1	14.4


geoid	county
17031010100	Cook County
17031010201	Cook County
17031010202	Cook County
17031010300	Cook County
17031010400	Cook County
17031010501	Cook County

geoid	county
17031010502	Cook County
17031010503	Cook County
17031010600	Cook County
17031010701	Cook County
17031010702	Cook County
17031020100	Cook County
17031020200	Cook County
17031020301	Cook County
17031020302	Cook County

Cómo se lee. Cada fila es un census tract (unidad de análisis, identificado por su GEOID de 11 dígitos) y cada columna un indicador de CDC PLACES expresado como prevalencia en adultos (%). Se muestran las primeras 15 filas.

Interpretación. El dataset tiene 1632 filas y 23 columnas, con 2 condados. Los valores son estimaciones de área pequeña publicadas por el CDC (modelo con BRFSS + Census ACS), no conteos de pacientes: son datos agregados, públicos y sin información identificable.

2. Calidad de datos: completitud por variable



Código	Variable	Dominio	Rol	Observados	Faltantes	Completitud %
pct_no_health_insurance	Sin seguro médico (%)	Acceso a salud	Entrada (X)	1632	0	100
pct_food_insecurity	Inseguridad alimentaria (%)	Alimentación	Entrada (X)	1632	0	100
pct_food_stamps	Recibe ayuda alimentaria (SNAP) (%)	Ingreso	Entrada (X)	1632	0	100

Código	Variable	Dominio	Rol	Observados	Faltantes	Compleitud %
pct_housing_insecurity	Inseguridad de vivienda (%)	Vivienda	Entrada (X)	1632	0	100
pct_utility_shutoff	Amenaza de corte de servicios (%)	Vivienda	Entrada (X)	1632	0	100
pct_no_transportation	Falta de transporte confiable (%)	Transporte	Entrada (X)	1632	0	100
pct_lack_social_support	Falta de apoyo social (%)	Social	Entrada (X)	1632	0	100
pct_loneliness	Soledad (%)	Social	Entrada (X)	1632	0	100
pct_routine_checkup	Chequeo médico anual (%)	Prevención	Entrada (X)	1632	0	100
pct_cholesterol_screening	Cribado de colesterol (%)	Prevención	Entrada (X)	1632	0	100
pct_smoking	Tabaquismo (%)	Comportamiento	Entrada (X)	1632	0	100
pct_inactivity	Inactividad física (%)	Comportamiento	Entrada (X)	1632	0	100
pct_binge_drinking	Consumo excesivo de alcohol (%)	Comportamiento	Entrada (X)	1632	0	100
pct_fair_poor_health	Salud autorreportada regular o mala (%)	Salud	Objetivo (y)	1632	0	100
pct_diabetes	Diabetes (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_obesity	Obesidad (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_high_bp	Hipertensión (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_chd	Enfermedad coronaria (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_depression	Depresión (%)	Salud mental	Objetivo (y)	1632	0	100
pct_mental_distress	Malestar mental frecuente (%)	Salud mental	Objetivo (y)	1632	0	100

Cómo se lee. Porcentaje de tracts con valor observado en cada variable. Una completitud baja reduce la muestra útil o exige imputar; las variables sin ningún dato no pueden usarse.

Interpretación. El dataset tiene 1632 census tracts. 20 de 20 variables están completas (≥ 99,9 %).

3. Verificaciones de integridad

Verificación	Casos	Estado
Unicidad del tract (GEOID duplicados)	0	OK
Plausibilidad (valores fuera de [0, 100] %)	0	OK
Celdas faltantes en variables del modelo	0	OK

Cómo se lee. Reglas de calidad de CRISP-DM aplicadas al dataset: cada tract debe aparecer una sola vez, las prevalencias deben estar entre 0 y 100 % y se cuentan los huecos que tendrá que imputar la fase III.

Interpretación. Sin duplicados de tract y todas las prevalencias son porcentajes válidos. No hay valores faltantes.

4. Estadística descriptiva: media, mediana, moda, dispersión y forma

Variable	n	Media	Mediana	Moda	Frec. moda	Nº modas	Media recortada 10%
Sin seguro médico (%)	1632	11.65	9.65	4.7	19	2	10.61
Inseguridad alimentaria (%)	1632	21.94	17.9	9	14	1	20.4
Recibe ayuda alimentaria (SNAP) (%)	1632	19.62	14.1	5.1	15	2	17.29
Inseguridad de vivienda (%)	1632	17.79	14.7	6.9	19	1	16.73
Amenaza de corte de servicios (%)	1632	10.7	8	4.2	31	1	9.528
Falta de transporte confiable (%)	1632	10.62	8.7	4.3	28	1	9.776
Falta de apoyo social (%)	1632	27.64	27	20.8	17	3	27.45
Soledad (%)	1632	35.85	35.6	36.9	22	1	35.77
Chequeo médico anual (%)	1632	77.59	77.9	76.2	31	1	77.64
Cribado de colesterol (%)	1632	87.39	87.65	88	25	1	87.55
Tabaquismo (%)	1632	11.33	10.7	11.8	23	1	10.82
Inactividad física (%)	1632	23.8	22.5	23.4	14	1	23.24

Variable	n	Media	Mediana	Moda	Frec. moda	Nº modas	Media recortada 10%
Consumo excesivo de alcohol (%)	1632	18.95	19	20.3	30	1	18.8
Salud autorreportada regular o mala (%)	1632	19.91	18.2	9.3	13	2	19.18
Diabetes (%)	1632	11.59	10.8	10.2	27	1	11.31
Obesidad (%)	1632	29.92	28.7	25.1	19	1	29.73
Hipertensión (%)	1632	30.19	28.95	29	20	1	29.88
Enfermedad coronaria (%)	1632	5.107	5.1	4.8	61	1	5.074
Depresión (%)	1632	19.02	18.9	19.1	49	1	18.99
Malestar mental frecuente (%)	1632	15.61	15.3	13.2	33	1	15.42

Variable	Desv. típica	CV %	Mín	Q1	Q3	Máx	RIC
Sin seguro médico (%)	7.416	63.66	2.1	6	15.3	41.9	9.3
Inseguridad alimentaria (%)	14.15	64.5	3.7	9.8	31.62	67.1	21.82
Recibe ayuda alimentaria (SNAP) (%)	15.58	79.42	2.5	7.2	27.8	74.4	20.6
Inseguridad de vivienda (%)	10.4	58.48	3.7	8.8	25.4	50.6	16.6
Amenaza de corte de servicios (%)	7.584	70.85	2.2	4.8	14.6	41.5	9.8
Falta de transporte confiable (%)	6.37	59.98	2.7	5.4	14.4	35.9	9
Falta de apoyo social (%)	5.602	20.27	16.3	22.8	32.1	44.5	9.3
Soledad (%)	4.095	11.42	26.4	32.6	38.8	55.4	6.2
Chequeo médico anual (%)	3.705	4.775	67.5	74.7	80.3	86.6	5.6
Cribado de colesterol (%)	3.443	3.94	69.4	85.1	90	95.2	4.9
Tabaquismo (%)	4.923	43.46	3.7	7.5	13.72	37.7	6.225
Inactividad física (%)	9.154	38.46	8.5	16	30.62	53.4	14.62
Consumo excesivo de alcohol (%)	4.103	21.65	9.2	15.97	21.1	30.8	5.125
Salud autorreportada regular o mala (%)	8.921	44.82	6.7	12.4	26.4	52.8	14
Diabetes (%)	4.918	42.42	1.7	8.075	14.8	32.3	6.725
Obesidad (%)	8.825	29.5	11.6	24.2	36.02	52.8	11.82
Hipertensión (%)	8.544	28.3	9	25.2	34.7	58.4	9.5
Enfermedad coronaria (%)	1.742	34.11	0.8	4.1	6.1	15.5	2
Depresión (%)	1.695	8.911	12.2	17.9	20.1	25.1	2.2
Malestar mental frecuente (%)	2.865	18.35	9.6	13.6	17.2	27.2	3.6

Variable	MAD	Asimetría	Curtosis (exceso)
Sin seguro médico (%)	6.301	1.198	1.049
Inseguridad alimentaria (%)	14.09	0.801	-0.248
Recibe ayuda alimentaria (SNAP) (%)	12.38	1.179	0.695
Inseguridad de vivienda (%)	10.53	0.741	-0.408
Amenaza de corte de servicios (%)	5.634	1.314	1.317
Falta de transporte confiable (%)	5.782	1.1	0.755
Falta de apoyo social (%)	6.968	0.241	-0.975
Soledad (%)	4.596	0.25	-0.23
Chequeo médico anual (%)	4.003	-0.128	-0.723
Cribado de colesterol (%)	3.632	-0.544	0.709
Tabaquismo (%)	4.596	1.018	1.317
Inactividad física (%)	10.82	0.471	-0.587
Consumo excesivo de alcohol (%)	3.855	0.276	-0.336
Salud autorreportada regular o mala (%)	9.859	0.644	-0.277
Diabetes (%)	4.744	0.559	-0.044
Obesidad (%)	8.006	0.276	-0.546
Hipertensión (%)	6.746	0.391	-0.211
Enfermedad coronaria (%)	1.483	0.52	1.887
Depresión (%)	1.631	0.121	0.41
Malestar mental frecuente (%)	2.669	0.666	0.43

Cómo se lee. Cada fila resume una variable sobre todos los census tracts. Tendencia central: media (promedio aritmético, sensible a extremos), mediana (valor central, robusta), moda (valor más frecuente, redondeado a 1 decimal como publica CDC) y media recortada al 10 % (promedio sin el 10 % más alto ni el más bajo). Dispersión: desviación típica, CV (desv./media), RIC (Q3–Q1) y MAD (desviación absoluta mediana escalada, robusta). Forma: asimetría (0 = simétrica; > 0 cola derecha) y curtosis de exceso (0 = normal; > 0 colas pesadas).

Interpretación. Se describen 20 variables. 11 presentan asimetría positiva relevante (media > mediana) y 4 son leptocúrticas, lo que anticipa valores atípicos y falta de normalidad. La mayor desigualdad entre tracts está en «Recibe ayuda alimentaria (SNAP) (%)» (CV = 79.4 %) y la menor en «Cribado de colesterol (%)» (CV = 3.9 %). Cuando media y mediana divergen, conviene resumir con mediana/RIC y usar pruebas no paramétricas en la fase inferencial.

5. Lectura de media, mediana, moda, asimetría y curtosis por variable

Variable	Lectura
Sin seguro médico (%)	«Sin seguro médico (%)»: media 11.65, mediana 9.65 y moda 4.7 (se repite 19 veces, con 2 valores empatados). La media está 2.00 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.20) y leptocúrtica (colas pesadas: más valores extremos que una normal) (curtosis de exceso = 1.05). El coeficiente de variación es 63.7 %: dispersión alta entre tracts (desigualdad territorial marcada).
Inseguridad alimentaria (%)	«Inseguridad alimentaria (%)»: media 21.94, mediana 17.90 y moda 9.0 (se repite 14 veces). La media está 4.04 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.80) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.25). El coeficiente de variación es 64.5 %: dispersión alta entre tracts (desigualdad territorial marcada).
Recibe ayuda alimentaria (SNAP) (%)	«Recibe ayuda alimentaria (SNAP) (%)»: media 19.62, mediana 14.10 y moda 5.1 (se repite 15 veces, con 2 valores empatados). La media está 5.52 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.18) y mesocúrtica (colas similares a una normal) (curtosis de exceso = 0.69). El coeficiente de variación es 79.4 %: dispersión alta entre tracts (desigualdad territorial marcada).
Inseguridad de vivienda (%)	«Inseguridad de vivienda (%)»: media 17.79, mediana 14.70 y moda 6.9 (se repite 19 veces). La media está 3.09 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.74) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.41). El coeficiente de variación es 58.5 %: dispersión alta entre tracts (desigualdad territorial marcada).
Amenaza de corte de servicios (%)	«Amenaza de corte de servicios (%)»: media 10.70, mediana 8.00 y moda 4.2 (se repite 31 veces). La media está 2.70 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.31) y leptocúrtica (colas pesadas: más valores extremos que una normal) (curtosis de exceso = 1.32). El coeficiente de variación es 70.8 %: dispersión alta entre tracts (desigualdad territorial marcada).
Falta de transporte confiable (%)	«Falta de transporte confiable (%)»: media 10.62, mediana 8.70 y moda 4.3 (se repite 28 veces). La media está 1.92 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.10) y mesocúrtica (colas similares a una normal) (curtosis de exceso = 0.76). El coeficiente de variación es 60.0 %: dispersión alta entre tracts (desigualdad territorial marcada).
Falta de apoyo social (%)	«Falta de apoyo social (%)»: media 27.64, mediana 27.00 y moda 20.8 (se repite 17 veces, con 3 valores empatados). La media está 0.64 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.24) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.97). El coeficiente de variación es 20.3 %: dispersión moderada.
Soledad (%)	«Soledad (%)»: media 35.85, mediana 35.60 y moda 36.9 (se repite 22 veces). La media está 0.25 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.25) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.23). El coeficiente de variación es 11.4 %: dispersión baja (tracts homogéneos).
Chequeo médico anual (%)	«Chequeo médico anual (%)»: media 77.59, mediana 77.90 y moda 76.2 (se repite 31 veces). La media está 0.31 puntos por debajo de la mediana: los valores bajos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = -0.13) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.72). El coeficiente de variación es 4.8 %: dispersión baja (tracts homogéneos).
Cribado de colesterol (%)	«Cribado de colesterol (%)»: media 87.39, mediana 87.65 y moda 88.0 (se repite 25 veces). La media está 0.26 puntos por debajo de la mediana: los valores bajos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la izquierda (cola de valores bajos) (asimetría = -0.54) y mesocúrtica (colas similares a una normal) (curtosis de exceso = 0.71). El coeficiente de variación es 3.9 %: dispersión baja (tracts homogéneos).

Variable	Lectura
Tabaquismo (%)	«Tabaquismo (%)»: media 11.33, mediana 10.70 y moda 11.8 (se repite 23 veces). La media está 0.63 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.02) y leptocúrtica (colas pesadas: más valores extremos que una normal) (curtosis de exceso = 1.32). El coeficiente de variación es 43.5 %: dispersión alta entre tracts (desigualdad territorial marcada).
Inactividad física (%)	«Inactividad física (%)»: media 23.80, mediana 22.50 y moda 23.4 (se repite 14 veces). La media está 1.30 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.47) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.59). El coeficiente de variación es 38.5 %: dispersión alta entre tracts (desigualdad territorial marcada).
Consumo excesivo de alcohol (%)	«Consumo excesivo de alcohol (%)»: media 18.95, mediana 19.00 y moda 20.3 (se repite 30 veces). Media y mediana prácticamente coinciden, señal de una distribución centrada. La distribución es aproximadamente simétrica (asimetría = 0.28) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.34). El coeficiente de variación es 21.6 %: dispersión moderada.
Salud autorreportada regular o mala (%)	«Salud autorreportada regular o mala (%)»: media 19.91, mediana 18.20 y moda 9.3 (se repite 13 veces, con 2 valores empatados). La media está 1.71 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.64) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.28). El coeficiente de variación es 44.8 %: dispersión alta entre tracts (desigualdad territorial marcada).
Diabetes (%)	«Diabetes (%)»: media 11.59, mediana 10.80 y moda 10.2 (se repite 27 veces). La media está 0.79 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.56) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.04). El coeficiente de variación es 42.4 %: dispersión alta entre tracts (desigualdad territorial marcada).
Obesidad (%)	«Obesidad (%)»: media 29.92, mediana 28.70 y moda 25.1 (se repite 19 veces). La media está 1.22 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.28) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.55). El coeficiente de variación es 29.5 %: dispersión moderada.
Hipertensión (%)	«Hipertensión (%)»: media 30.19, mediana 28.95 y moda 29.0 (se repite 20 veces). La media está 1.24 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.39) y mesocúrtica (colas similares a una normal) (curtosis de exceso = -0.21). El coeficiente de variación es 28.3 %: dispersión moderada.
Enfermedad coronaria (%)	«Enfermedad coronaria (%)»: media 5.11, mediana 5.10 y moda 4.8 (se repite 61 veces). Media y mediana prácticamente coinciden, señal de una distribución centrada. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.52) y leptocúrtica (colas pesadas: más valores extremos que una normal) (curtosis de exceso = 1.89). El coeficiente de variación es 34.1 %: dispersión alta entre tracts (desigualdad territorial marcada).
Depresión (%)	«Depresión (%)»: media 19.02, mediana 18.90 y moda 19.1 (se repite 49 veces). La media está 0.12 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es aproximadamente simétrica (asimetría = 0.12) y mesocúrtica (colas similares a una normal) (curtosis de exceso = 0.41). El coeficiente de variación es 8.9 %: dispersión baja (tracts homogéneos).
Malestar mental frecuente (%)	«Malestar mental frecuente (%)»: media 15.61, mediana 15.30 y moda 13.2 (se repite 33 veces). La media está 0.31 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es moderadamente asimétrica a la derecha (cola de valores altos) (asimetría = 0.67) y mesocúrtica (colas similares a una normal) (curtosis de exceso = 0.43). El coeficiente de variación es 18.4 %: dispersión moderada.

Cómo se lee. Traducción automática de la tabla anterior para cada variable: compara media con mediana (sesgo), sitúa la moda, clasifica la asimetría ($|g| < 0,5$ simétrica; $0,5-1$ moderada; > 1 fuerte) y la curtosis de exceso (> 1 leptocúrtica, < -1 platocúrtica) y valora la dispersión por el CV.

Interpretación. Las 20 lecturas permiten decidir qué resumen usar en cada variable: la mediana cuando la distribución está sesgada y la media cuando es simétrica.


6. Diagramas de caja comparados



Cómo se lee. Cada caja abarca el 50 % central de los tracts (Q1–Q3) y la línea roja es la mediana. Las variables se estandarizan como $(x - \text{mediana})/\text{RIC}$ para que sean comparables en la misma escala. Los bigotes llegan a 1,5·RIC; los puntos ámbar fuera de ellos son valores atípicos según el criterio de Tukey.

Interpretación. Tras estandarizar, la cola superior más larga es la de «Enfermedad coronaria (%)»: su tract más alto está a 5.2 RIC por encima de la mediana. 8 de 20 variables tienen la mediana desplazada hacia el borde inferior de la caja (más masa por encima), otra señal de asimetría positiva. Colas superiores largas indican tracts con carga social excepcional, que el modelo debe aprender a reconocer y no descartar.


7. Distribución de «Sin seguro médico (%)» con media, mediana y moda



Cómo se lee. Histograma (barras) con la curva de densidad estimada por núcleos (KDE). Las líneas verticales marcan la media (roja), la mediana (verde discontinua) y la moda (ámbar punteada). Si las tres coinciden la distribución es simétrica; si la media queda a la derecha de la mediana hay una cola de tracts con valores altos.

Interpretación. «Sin seguro médico (%)»: media 11.65, mediana 9.65 y moda 4.7 (se repite 19 veces, con 2 valores empatados). La media está 2.00 puntos por encima de la mediana: los valores altos arrastran el promedio, por lo que la mediana es el resumen más representativo del tract típico. La distribución es fuertemente asimétrica a la derecha (cola de valores altos) (asimetría = 1.20) y leptocúrtica (colas pesadas: más valores extremos que una normal) (curtosis de exceso = 1.05). El coeficiente de variación es 63.7 %: dispersión alta entre tracts (desigualdad territorial marcada).

8. Detección de valores atípicos (Tukey, z-robusto, z clásico)



Variable	Límite inf. (Tukey)	Límite sup. (Tukey)	Atípicos IQR	% IQR	Atípicos z-robusto (>3,5)	Atípicos z clásico (>3)	Altos
Sin seguro médico (%)	-7.95	29.25	57	3.493	37	16	57
Inseguridad alimentaria (%)	-22.94	64.36	6	0.368	0	6	6
Recibe ayuda alimentaria (SNAP) (%)	-23.7	58.7	43	2.635	49	14	43
Inseguridad de vivienda (%)	-16.1	50.3	2	0.123	0	4	2
Amenaza de corte de servicios (%)	-9.9	29.3	50	3.064	64	21	50
Falta de transporte confiable (%)	-8.1	27.9	28	1.716	19	17	28
Falta de apoyo social (%)	8.85	46.05	0	0	0	1	0
Soledad (%)	23.3	48.1	4	0.245	2	3	4
Chequeo médico anual (%)	66.3	88.7	0	0	0	0	0
Cribado de colesterol (%)	77.75	97.35	8	0.49	6	8	0
Tabaquismo (%)	-1.837	23.06	46	2.819	12	15	46
Inactividad física (%)	-5.938	52.56	1	0.061	0	3	1
Consumo excesivo de alcohol (%)	8.287	28.79	12	0.735	0	0	12
Salud autorreportada regular o mala (%)	-8.6	47.4	3	0.184	1	4	3
Diabetes (%)	-2.013	24.89	10	0.613	4	6	10
Obesidad (%)	6.463	53.76	0	0	0	0	0
Hipertensión (%)	10.95	48.95	26	1.593	5	1	23
Enfermedad coronaria (%)	1.1	9.1	31	1.9	12	12	30

Variable	Límite inf. (Tukey)	Límite sup. (Tukey)	Atípicos IQR	% IQR	Atípicos z-robusto (>3,5)	Atípicos z clásico (>3)	Altos
Depresión (%)	14.6	23.4	22	1.348	5	8	13
Malestar mental frecuente (%)	8.2	22.6	35	2.145	7	10	35

Variable	Bajos
Sin seguro médico (%)	0
Inseguridad alimentaria (%)	0
Recibe ayuda alimentaria (SNAP) (%)	0
Inseguridad de vivienda (%)	0
Amenaza de corte de servicios (%)	0
Falta de transporte confiable (%)	0
Falta de apoyo social (%)	0
Soledad (%)	0
Chequeo médico anual (%)	0
Cribado de colesterol (%)	8
Tabaquismo (%)	0
Inactividad física (%)	0
Consumo excesivo de alcohol (%)	0
Salud autorreportada regular o mala (%)	0
Diabetes (%)	0
Obesidad (%)	0
Hipertensión (%)	3
Enfermedad coronaria (%)	1
Depresión (%)	9
Malestar mental frecuente (%)	0

Cómo se lee. Tres criterios complementarios: (1) Tukey/IQR — fuera de [Q1 – 1,5·RIC, Q3 + 1,5·RIC]; (2) z-robusto de Iglewicz-Hoaglin — $|0,6745 \cdot (x - \text{mediana})/\text{MAD}| > 3,5$, que no se deja arrastrar por los propios atípicos; (3) z clásico — $|x - \text{media}|/\text{desv.} > 3$, válido solo si la variable es aproximadamente normal. Coincidencia entre criterios = atípico robusto.

Interpretación. En total se marcan 384 valores atípicos por Tukey (363 por arriba y 21 por abajo) y 223 por z-robusto. La variable con más atípicos es «Sin seguro médico (%)» (57 tracts, 3.5 %). 3 variables no tienen atípicos. Los atípicos por arriba son tracts con carga social o sanitaria excepcional: no son errores de medición (CDC ya publica estimaciones suavizadas) sino los casos de mayor prioridad, por eso no se eliminan. Para que no dominen el ajuste se usan medianas en la imputación, escalado estándar dentro del pipeline y modelos de árboles robustos a extremos.

9. Tracts atípicos en «Sin seguro médico (%)»

geoid	name	county	pct_no_health_insurance
17031611400	17031611400	Cook County	41.9
17031300800	17031300800	Cook County	40.5
17031301702	17031301702	Cook County	38.8
17031301600	17031301600	Cook County	38.3
17031611500	17031611500	Cook County	37
17031840800	17031840800	Cook County	36.7
17031813302	17031813302	Cook County	36.3
17031300900	17031300900	Cook County	35.9
17031300600	17031300600	Cook County	35.5
17031191200	17031191200	Cook County	34.9
17031301100	17031301100	Cook County	34.7
17031520100	17031520100	Cook County	34.6
17031770500	17031770500	Cook County	34.5
17031813301	17031813301	Cook County	34.4
17031301802	17031301802	Cook County	34.3
17031814300	17031814300	Cook County	33.9
17031611300	17031611300	Cook County	33.6
17031630300	17031630300	Cook County	33.5
17031630400	17031630400	Cook County	33.4
17031816600	17031816600	Cook County	33.2
17031612200	17031612200	Cook County	33.1
17031813801	17031813801	Cook County	33
17031816402	17031816402	Cook County	33
17031301701	17031301701	Cook County	32.9

geoid	name	county	pct_no_health_insurance
17031191302	17031191302	Cook County	32.9
17031191100	17031191100	Cook County	32.8
17031190702	17031190702	Cook County	32.8
17031660400	17031660400	Cook County	32.6
17031230700	17031230700	Cook County	32.6
17031610300	17031610300	Cook County	32.5
17031610400	17031610400	Cook County	32.5
17031580700	17031580700	Cook County	32.4
17031300500	17031300500	Cook County	32.4
17031630500	17031630500	Cook County	32.2
17031830500	17031830500	Cook County	32.1
17031831300	17031831300	Cook County	32
17031300700	17031300700	Cook County	31.9
17031814100	17031814100	Cook County	31.6
17031816401	17031816401	Cook County	31.6
17031842800	17031842800	Cook County	31.5
17031630600	17031630600	Cook County	31.5
17031650302	17031650302	Cook County	31.4
17031301803	17031301803	Cook County	31.2
17031230600	17031230600	Cook County	31
17031813400	17031813400	Cook County	31

(Se muestran 45 de 57 filas.)

Cómo se lee. Listado de los census tracts que quedan fuera de las vallas de Tukey para la variable elegida, ordenados de mayor a menor valor.

Interpretación. 57 tracts atípicos; el más extremo es 17031611400 (Cook County) con 41.9 %, frente a una valla superior de 29.2 %. Son candidatos naturales a intervención prioritaria si la variable es de riesgo.

10. Pruebas de normalidad (Shapiro-Wilk, D'Agostino-Pearson, Anderson-Darling)


Variable	Shapiro-Wilk W	p Shapiro	D'Agostino K²	p D'Agostino	Anderson-Darling A²	A² crítico 5%	¿Normal? (α=0,05)
Sin seguro médico (%)	0.8924	0	289.1	0	50.35	0.752	No
Inseguridad alimentaria (%)	0.9134	0	143.3	0	44.58	0.752	No
Recibe ayuda alimentaria (SNAP) (%)	0.8665	0	267.7	0	70.33	0.752	No
Inseguridad de vivienda (%)	0.9168	0	139.3	0	44.8	0.752	No
Amenaza de corte de servicios (%)	0.8581	0	336.2	0	72.95	0.752	No
Falta de transporte confiable (%)	0.8935	0	246.9	0	51.92	0.752	No
Falta de apoyo social (%)	0.9675	0	331.3	0	16.38	0.752	No
Soledad (%)	0.9892	0	21.01	0	4.493	0.752	No
Chequeo médico anual (%)	0.9862	0	99.02	0	6.617	0.752	No
Cribado de colesterol (%)	0.9804	0	91.47	0	4.279	0.752	No
Tabaquismo (%)	0.9367	0	247.9	0	21.68	0.752	No
Inactividad física (%)	0.9615	0	103.6	0	17.24	0.752	No
Consumo excesivo de alcohol (%)	0.9812	0	31.14	0	7.976	0.752	No
Salud autorreportada regular o mala (%)	0.9483	0	102.7	0	22.87	0.752	No
Diabetes (%)	0.9731	0	75	0	11.84	0.752	No
Obesidad (%)	0.9759	0	59.43	0	11.55	0.752	No
Hipertensión (%)	0.9737	0	42.67	0	18.29	0.752	No
Enfermedad coronaria (%)	0.9774	0	139.3	0	4.176	0.752	No
Depresión (%)	0.9958	0.0002	12.43	0.002	1.962	0.752	No
Malestar mental frecuente (%)	0.973	0	110.7	0	11.25	0.752	No

Cómo se lee. Tres pruebas con H0 = «la variable sigue una distribución normal». Shapiro-Wilk (la más potente en muestras moderadas), D'Agostino-Pearson K² (combina asimetría y curtosis) y Anderson-Darling (sensible a las colas; se rechaza si A² supera su valor crítico al 5 %). $p < 0,05 \rightarrow$ se rechaza la normalidad.

Interpretación. 20 de 20 variables rechazan la normalidad en al menos una de las tres pruebas ($\alpha = 0,05$). Con $n \approx 1632$ tracts las pruebas detectan desviaciones pequeñas; por eso se complementan con el tamaño de la asimetría/curtosis y el gráfico Q-Q. Conclusión metodológica: los supuestos de las pruebas paramétricas clásicas (t, ANOVA, Pearson) no se sostienen, y la fase inferencial usa alternativas robustas: Spearman, Kruskal-Wallis, Friedman/Nemenyi, Wilcoxon, McNemar

exacto, bootstrap y permutaciones.


11. Gráfico Q-Q normal de «Sin seguro médico (%)»



Cómo se lee. Cada punto enfrenta un cuantil observado con el que tendría una normal. Si los puntos siguen la recta roja la variable es normal; una curva en forma de «U» o de «J» indica asimetría y puntos que se separan en los extremos indican colas pesadas (atípicos).

Interpretación. En «Sin seguro médico (%)» los puntos se curvan hacia arriba a la derecha (asimetría positiva) y se separan de la recta en los extremos (colas más pesadas que la normal); asimetría 1.20, curtosis de exceso 1.04.

12. Matriz de correlación de Spearman



Cómo se lee. ρ de Spearman: correlación entre los rangos de dos variables, robusta a atípicos y a relaciones monótonas no lineales (adecuada porque las variables no son normales). Rojo = asociación positiva (suben juntas), azul = negativa; $|\rho| \geq 0,7$ fuerte, 0,4–0,7 moderada, $< 0,4$ débil. Correlación no implica causalidad.

Interpretación. De 190 pares, 106 tienen $|\rho| \geq 0,7$ (asociación fuerte). El más fuerte es «Inseguridad alimentaria (%)» con «Falta de transporte confiable (%)» ($\rho = +0.99$). Esta multicolinealidad significa que los determinantes sociales se acumulan en los mismos tracts; los modelos de árboles la toleran, pero la importancia de cada variable debe leerse como compartida con sus correlacionadas.

III. Preparación de los datos


13. Pipeline de preparación

Conjunto	n	Bajo	Moderado	Alto	Crítico
Entrenamiento	1305	333	322	325	325
Prueba	327	83	80	82	82

Cómo se lee. Pipeline de preparación idéntico al de la API: (1) partición train/test estratificada por cuartiles del objetivo, (2) discretización en 4 niveles con cortes de train, (3) imputación por mediana y (4) estandarización. Imputación y escalado se ajustan dentro de cada fold de validación cruzada, evitando fuga de información.

Interpretación. El objetivo «Salud autorreportada regular o mala (%)» (%) se convierte en 4 niveles de riesgo usando los cuartiles del conjunto de entrenamiento: Bajo < 12.4 %, Moderado 12.4–18.2 %, Alto 18.2–26.4 %, Crítico ≥ 26.4 %. Los cortes se calculan solo con train para que el conjunto de prueba (20 %) no filtre información. Las clases quedan equilibradas (≈25 % cada una), de modo que F1-macro y accuracy son comparables y la línea base al azar ronda 0,25. Hay 0 celdas faltantes en train, que imputa la mediana dentro del pipeline; después se estandarizan las 13 entradas (media 0, varianza 1).

14. Definición de los niveles de riesgo



Cómo se lee. Histograma del resultado de salud coloreado por el nivel asignado. Las líneas discontinuas son los cuartiles Q1, Q2 (mediana) y Q3 calculados solo con el conjunto de entrenamiento.

Interpretación. Los cortes quedan en 12.4 %, 18.2 % y 26.4 %. El nivel Crítico agrupa el 25 % de tracts con mayor prevalencia de adultos que califican su salud como regular o mala, desde 26.4 % hasta 52.8 %: es un rango más amplio que el de los demás niveles por la asimetría positiva observada en el EDA. Los niveles son relativos al área de estudio, no umbrales clínicos.

IV. Modelado (entrenamiento, hiperparámetros, validación cruzada, selección)


15. Algoritmos candidatos y espacio de búsqueda

Modelo	Rol	Hiperparámetros a buscar	Configuraciones
Regresión Logística	Línea base lineal e interpretable	$C \in [0.01, 0.1, 1.0, 10.0, 100.0]$	5
Random Forest	Ensamble de árboles (bagging), robusto a no linealidades	$\text{max_depth} \in [\text{None}, 10]$; $\text{min_samples_leaf} \in [1, 4]$	4
Gradient Boosting	Boosting de árboles (tipo XGBoost), fuerte en datos tabulares	$\text{learning_rate} \in [0.05, 0.1]$; $\text{max_depth} \in [\text{None}, 6]$	4
Red Neuronal (MLP)	Perceptrón multicapa, enfoque de deep learning	$\text{hidden_layer_sizes} \in [(32,), (64, 32)]$; $\alpha \in [0.0001, 0.01]$	4
Línea base (azar estratificado)	Referencia: predice al azar respetando la frecuencia de clases	—	1

Cómo se lee. Cada fila es un algoritmo con su papel en la comparación y la rejilla de hiperparámetros que se explora. Todos comparten el mismo preprocesado (imputación por mediana + estandarización) dentro de un Pipeline de scikit-learn, de modo que la comparación es justa.

Interpretación. Se comparan familias complementarias: un modelo lineal interpretable, dos ensambles de árboles (bagging y boosting) y una red neuronal, más una línea base aleatoria que fija el suelo de desempeño. En total 18 configuraciones × 5 particiones.

16. Resultados del entrenamiento



Modelo	Rol	Configs. probadas	Mejores hiper parámetros	F1 train	F1 CV	F1 test	Accuracy test
Regresión Logística	Línea base lineal e interpretable	5	$C=100.0$	0.9879	0.977	0.9846	0.9847
Gradient Boosting	Boosting de árboles (tipo XGBoost), fuerte en datos tabulares	4	$\text{learning_rate}=0.1, \text{max_dept}=\text{None}$	1	0.957	0.963	0.9633
Random Forest	Ensamble de árboles (bagging), robusto a no linealidades	4	$\text{max_depth}=10, \text{min_sample_s_leaf}=1$	1	0.9561	0.948	0.948
Red Neuronal (MLP)	Perceptrón multicapa, enfoque de deep learning	4	$\alpha=0.0001, \text{hidden_layer_sizes}=(64, 32)$	0.9181	0.9081	0.9477	0.948
Línea base (azar estratificado)	Referencia: predice al azar respetando la frecuencia de clases	1	$\text{strategy}=\text{stratified}$	0.2492	0.2433	0.2187	0.2232


Modelo	ROC-AUC test	Tiempo (s)	Estado
Regresión Logística	0.9996	4.554	Seleccionado

Modelo	ROC-AUC test	Tiempo (s)	Estado
Gradient Boosting	0.9983	4.548	Candidato
Random Forest	0.9972	2.841	Candidato
Red Neuronal (MLP)	0.9965	1.22	Candidato
Línea base (azar estratificado)	0.4817	0.0973	Referencia

Cómo se lee. Cada algoritmo se entrena con búsqueda en rejilla (GridSearchCV) sobre el conjunto de entrenamiento. F1 train = ajuste sobre los datos vistos; F1 CV = promedio en los folds de validación (no vistos en cada ajuste); F1 test = evaluación final sobre el 20 % reservado. F1-macro promedia el F1 de las 4 clases por igual, de modo que no favorece a ninguna. ROC-AUC (uno contra el resto) mide la capacidad de ordenar tracts por riesgo (0,5 = azar, 1 = perfecto).

Interpretación. Se entrenaron 4 algoritmos más una línea base al azar, probando en total 17 configuraciones de hiperparámetros con 5 particiones de validación cruzada cada una (14 s). El mejor, Regresión Logística, alcanza F1-macro 0.977 en CV y 0.985 en prueba, frente a 0.243 del azar: el modelo aprende una señal real de los determinantes sociales (4.0× la línea base). El peor candidato es Red Neuronal (MLP) (0.908). La brecha train–CV del mejor es 0.011: sin sobreajuste apreciable.

17. Hiperparámetros · Regresión Logística




Configuración	F1 CV (media)	F1 CV (desv.)	F1 train (media)	Accuracy CV	Tiempo ajuste (s)	Ranking
C=100.0	0.977	0.0144	0.9879	0.977	0.0802	1
C=10.0	0.9724	0.0152	0.9829	0.9724	0.0621	2
C=1.0	0.9515	0.0102	0.9606	0.9517	0.0439	3
C=0.1	0.9193	0.0106	0.9271	0.9195	0.0422	4
C=0.01	0.8742	0.0154	0.8788	0.8759	0.0313	5

Cómo se lee. Búsqueda exhaustiva en rejilla (GridSearchCV): cada combinación se evalúa con la misma validación cruzada estratificada repetida y se elige la de mayor F1-macro medio. La barra verde es la configuración ganadora; la barra de error es ± 1 desviación entre folds y la marca roja el F1 sobre train (su distancia a la barra mide el sobreajuste).

Interpretación. Regresión Logística: se probaron 5 configuraciones; la ganadora es «C=100.0» con F1 CV = 0.9770 ± 0.0144 . La diferencia entre la mejor y la peor configuración es 0.1028, mayor que la variabilidad entre folds: la sintonía de hiperparámetros sí mejora el modelo. Significado: C: inverso de la regularización L2 (C pequeño = modelo más simple).

18. Hiperparámetros · Gradient Boosting




Configuración	F1 CV (media)	F1 CV (desv.)	F1 train (media)	Accuracy CV	Tiempo ajuste (s)	Ranking
learning_rate=0.1, max_depth=None	0.957	0.0143	1	0.9571	1.182	1
learning_rate=0.1, max_depth=6	0.9555	0.0156	1	0.9556	0.734	2
learning_rate=0.05, max_depth=None	0.9555	0.0141	1	0.9556	1.826	3
learning_rate=0.05, max_depth=6	0.9548	0.0154	1	0.9548	1.147	4

Cómo se lee. Búsqueda exhaustiva en rejilla (GridSearchCV): cada combinación se evalúa con la misma validación cruzada estratificada repetida y se elige la de mayor F1-macro medio. La barra verde es la configuración ganadora; la barra de error es ± 1 desviación entre folds y la marca roja el F1 sobre train (su distancia a la barra mide el sobreajuste).

Interpretación. Gradient Boosting: se probaron 4 configuraciones; la ganadora es «learning_rate=0.1, max_depth=None» con F1 CV = 0.9570 ± 0.0143 . La diferencia entre la mejor y la peor configuración es 0.0022, menor que la variabilidad entre folds: el modelo es poco sensible a estos hiperparámetros y la elección concreta apenas importa. Significado: learning_rate: tamaño del paso del boosting (bajo = aprendizaje más gradual); max_depth: profundidad máxima de cada árbol (None = sin límite).

19. Hiperparámetros · Random Forest




Configuración	F1 CV (media)	F1 CV (desv.)	F1 train (media)	Accuracy CV	Tiempo ajuste (s)	Ranking
max_depth=10, min_samples_leaf=1	0.9561	0.0131	1	0.9563	0.7273	1
max_depth=None, min_samples_leaf=1	0.9538	0.013	1	0.954	0.8032	2
max_depth=10, min_samples_leaf=4	0.9453	0.0139	0.9867	0.9456	0.518	3
max_depth=None, min_samples_leaf=4	0.9446	0.0133	0.9869	0.9448	0.728	4

Cómo se lee. Búsqueda exhaustiva en rejilla (GridSearchCV): cada combinación se evalúa con la misma validación cruzada estratificada repetida y se elige la de mayor F1-macro medio. La barra verde es la configuración ganadora; la barra de error es ± 1 desviación entre folds y la marca roja el F1 sobre train (su distancia a la barra mide el sobreajuste).

Interpretación. Random Forest: se probaron 4 configuraciones; la ganadora es «max_depth=10, min_samples_leaf=1» con F1 CV = 0.9561 ± 0.0131 . La diferencia entre la mejor y la peor configuración es 0.0115, menor que la variabilidad entre folds: el modelo es poco sensible a estos hiperparámetros y la elección concreta apenas importa. Significado: max_depth: profundidad máxima de cada árbol (None = sin límite); min_samples_leaf: mínimo de tracts por hoja (más alto = árboles más suaves).

20. Hiperparámetros · Red Neuronal (MLP)




Configuración	F1 CV (media)	F1 CV (desv.)	F1 train (media)	Accuracy CV	Tiempo ajuste (s)	Ranking
alpha=0.0001, hidden_layer_sizes=(64, 32)	0.9081	0.0196	0.9181	0.9088	0.2935	1
alpha=0.01, hidden_layer_sizes=(64, 32)	0.9073	0.0189	0.9196	0.908	0.2162	2
alpha=0.0001, hidden_layer_sizes=(32,)	0.8637	0.017	0.8645	0.8659	0.2466	3
alpha=0.01, hidden_layer_sizes=(32,)	0.8637	0.017	0.8645	0.8659	0.2525	3

Cómo se lee. Búsqueda exhaustiva en rejilla (GridSearchCV): cada combinación se evalúa con la misma validación cruzada estratificada repetida y se elige la de mayor F1-macro medio. La barra verde es la configuración ganadora; la barra de error es ± 1 desviación entre folds y la marca roja el F1 sobre train (su distancia a la barra mide el sobreajuste).

Interpretación. Red Neuronal (MLP): se probaron 4 configuraciones; la ganadora es «alpha=0.0001, hidden_layer_sizes=(64, 32)» con F1 CV = 0.9081 ± 0.0196 . La diferencia entre la mejor y la peor configuración es 0.0444, mayor que la variabilidad entre folds: la sintonía de hiperparámetros sí mejora el modelo. Significado: alpha: penalización L2 de los pesos de la red; hidden_layer_sizes: neuronas por capa oculta.

21. Distribución del F1 por fold




Modelo	Folds	F1 medio	Desv.	IC95% inf.	IC95% sup.	Mín	Máx
Regresión Logística	5	0.977	0.0161	0.957	0.9969	0.954	0.9924
Gradient Boosting	5	0.957	0.016	0.9372	0.9769	0.9389	0.9768
Random Forest	5	0.9561	0.0146	0.9379	0.9743	0.9391	0.9768
Red Neuronal (MLP)	5	0.9081	0.0219	0.8809	0.9353	0.8837	0.9307
Línea base (azar estratificado)	5	0.2433	0.0314	0.2044	0.2822	0.2086	0.2804

Modelo	CV del F1 %
Regresión Logística	1.643
Gradient Boosting	1.669
Random Forest	1.532
Red Neuronal (MLP)	2.412
Línea base (azar estratificado)	12.89

Cómo se lee. Validación cruzada estratificada repetida: el conjunto de entrenamiento se divide en k partes con la misma proporción de niveles; se entrena en k-1 y se valida en la restante, rotando, y todo se repite con otra semilla. Todos los modelos usan exactamente las mismas particiones, lo que permite compararlos por pares. Cada punto es el F1 de un fold; el IC 95 % usa la distribución t de Student.

Interpretación. El mejor modelo (Regresión Logística) obtiene F1 = 0.9770 con IC 95 % [0.9570, 0.9969] sobre 5 folds; su F1 oscila entre 0.954 y 0.992. Su intervalo se solapa con el del segundo (Gradient Boosting), por lo que la diferencia puede no ser real: se contrasta formalmente en «Pruebas inferenciales». El modelo más estable entre particiones es Random Forest (desv. 0.0146). Una desviación baja indica que el desempeño no depende de qué tracts caen en cada fold.

22. Curva de aprendizaje del modelo seleccionado



Cómo se lee. Se reentrena el modelo seleccionado con fracciones crecientes del entrenamiento (15 %–100 %) y se mide el F1 en train y en validación (5 folds). Bandas = ± 1 desviación. Si ambas curvas convergen en un valor bajo hay sesgo (modelo demasiado simple); si quedan separadas hay varianza (sobreajuste) y más datos ayudarían.

Interpretación. Con 156 tracts el F1 de validación es 0.934 y con 1044 llega a 0.977; el último incremento de datos aporta +0.002. La curva se ha estabilizado: más datos del mismo tipo aportarían poco. La distancia final train–validación es 0.011 (varianza contenida).

23. Ranking de candidatos y criterio de selección


Puesto	Modelo	F1 CV	$\pm$ desv.	F1 test	Accuracy balanceada	Kappa de Cohen	ROC-AUC
1	Regresión Logística	0.977	0.0161	0.9846	0.9847	0.9796	0.9996
2	Gradient Boosting	0.957	0.016	0.963	0.963	0.9511	0.9983
3	Random Forest	0.9561	0.0146	0.948	0.9479	0.9307	0.9972
4	Red Neuronal (MLP)	0.9081	0.0219	0.9477	0.9476	0.9307	0.9965

Puesto	Sobreajuste (train–CV)	Tiempo (s)
1	0.0109	4.554
2	0.043	4.548
3	0.0439	2.841
4	0.0101	1.22

Cómo se lee. Ranking de candidatos por F1-macro en validación cruzada. Se añaden métricas de prueba complementarias: accuracy balanceada (media de sensibilidades), kappa de Cohen (acuerdo corregido por azar: 0 = azar, 1 = perfecto), ROC-AUC y la brecha train–CV como indicador de sobreajuste.

Interpretación. Criterio declarado: mayor F1-macro medio en validación cruzada (el test no se usa para elegir, solo para confirmar). Gana Regresión Logística con 0.9770, +0.0200 sobre Gradient Boosting. En prueba confirma F1 = 0.9846, ROC-AUC = 0.9996 y kappa = 0.980 (acuerdo casi perfecto más allá del azar). El más rápido es Red Neuronal (MLP) (1.2 s). Si la ventaja del ganador no resulta estadísticamente significativa en la fase inferencial, un modelo más simple o rápido sería una alternativa igualmente defendible.

24. Matriz de confusión del modelo seleccionado



Cómo se lee. Filas = nivel real del tract, columnas = nivel predicho por el modelo, sobre el 20 % de prueba que nunca participó en el entrenamiento. Cada celda muestra el número de tracts y el porcentaje de su fila (sensibilidad por clase en la diagonal). Un modelo perfecto concentra todo en la diagonal.

Interpretación. De 327 tracts de prueba, 322 (98%) se clasifican en su nivel exacto y 5 (2%) en un nivel vecino; solo 0 (0%) fallan por dos o más niveles. Los errores se concentran junto a la diagonal porque los niveles son cuartiles de una variable continua: confundir Alto con Crítico es un error de frontera, no de concepto. La clase mejor reconocida es Crítico (sensibilidad 100%) y la peor Moderado (98%); las clases intermedias suelen ser las más difíciles al tener vecinos por ambos lados. Para priorizar intervenciones importa el nivel Crítico: sensibilidad 100% y precisión 100%.


25. Métricas por nivel de riesgo

Nivel	Precisión	Sensibilidad (recall)	F1	Soporte
Bajo	0.9878	0.9759	0.9818	83
Moderado	0.963	0.975	0.9689	80
Alto	0.9878	0.9878	0.9878	82
Crítico	1	1	1	82
Promedio macro	0.9846	0.9847	0.9846	327

Cómo se lee. Precisión: de los tracts que el modelo etiqueta con ese nivel, qué fracción lo es realmente (pocas falsas alarmas). Sensibilidad: de los tracts que realmente son de ese nivel, qué fracción detecta (pocos casos perdidos). F1: media armónica de ambas. Soporte: tracts reales de cada nivel en prueba.

Interpretación. El nivel mejor predicho es Crítico (F1 = 1.000) y el más difícil Moderado (F1 = 0.969). Los niveles extremos (Bajo y Crítico) suelen separarse mejor porque sus determinantes sociales son más distintivos; los intermedios comparten perfil con dos vecinos. Si la precisión de Crítico supera a su sensibilidad, el modelo es conservador (marca pocos críticos pero acierta); si es al revés, detecta más casos a costa de falsas alarmas.


26. Curvas ROC por nivel



Cómo se lee. Para cada nivel se trata el problema como binario (ese nivel contra los demás) y se barre el umbral de probabilidad. La curva muestra cuántos verdaderos positivos se ganan a cambio de falsos positivos; la diagonal gris es el azar (AUC = 0,5). Cuanto más pegada a la esquina superior izquierda, mejor.

Interpretación. AUC macro = 1.000. Por nivel: Crítico 1.000, Alto 1.000, Bajo 1.000, Moderado 0.999. Un AUC de 0,9 significa que, tomando al azar un tract de ese nivel y otro que no lo es, el modelo asigna mayor probabilidad al correcto el 90 % de las veces. El nivel Moderado es el más difícil de separar del resto.

27. Explicabilidad global: importancia por permutación



Variable	Importancia	Desv.
Inactividad física (%)	0.3697	0.0144
Sin seguro médico (%)	0.2785	0.0134
Tabaquismo (%)	0.2325	0.0122
Chequeo médico anual (%)	0.1843	0.0141
Falta de transporte confiable (%)	0.1384	0.0135
Inseguridad de vivienda (%)	0.1028	0.0107
Inseguridad alimentaria (%)	0.0969	0.0102
Recibe ayuda alimentaria (SNAP) (%)	0.0766	0.0091
Cribado de colesterol (%)	0.0584	0.0146
Falta de apoyo social (%)	0.0576	0.0087
Amenaza de corte de servicios (%)	0.0516	0.0046
Consumo excesivo de alcohol (%)	0.0177	0.0049
Soledad (%)	0.0144	0.0073

Cómo se lee. Importancia por permutación (explicabilidad agnóstica al modelo): se desordenan al azar los valores de una variable en el conjunto de prueba, 10 veces, y se mide cuánto cae el F1-macro. Si el modelo depende de esa variable, desordenarla lo empeora mucho. Barra de error = ± 1 desv.

Interpretación. Las variables que más sostienen las predicciones son: «Inactividad física (%)» (−0.370 de F1 si se desordena), «Sin seguro médico (%)» (−0.279 de F1 si se desordena), «Tabaquismo (%)» (−0.233 de F1 si se desordena). 0 variables tienen una importancia indistinguible de cero (su efecto no supera su propia variabilidad). Al estar los determinantes correlacionados, una variable puede parecer poco importante porque otra correlacionada aporta la misma información; la importancia es predictiva, no causal.

V. Evaluación (pruebas inferenciales robustas)


28. Prueba de Friedman y post-hoc de Nemenyi

Modelo	Rango medio (1 = mejor)	Distancia al mejor	¿Distinguible del mejor? (Nemenyi)
Regresión Logística	1	0	—
Gradient Boosting	2.6	1.6	No
Random Forest	2.4	1.4	No
Red Neuronal (MLP)	4	3	Sí

Cómo se lee. Prueba de Friedman: alternativa no paramétrica al ANOVA de medidas repetidas. En cada fold se ordenan los modelos (1 = mejor F1) y se contrasta H0 «todos los modelos tienen el mismo rango medio». W de Kendall (0–1) es el tamaño del efecto. Post-hoc de Nemenyi: dos modelos difieren si sus rangos medios se separan más que la diferencia crítica CD (Demšar, 2006).

Interpretación. Friedman $\chi^2 = 13.56$ con 3 g.l., $p = 0.0036$ sobre 5 folds. Se rechaza H0: al menos un modelo rinde distinto. El tamaño del efecto (W de Kendall = 0.904) es grande, es decir, la ordenación de modelos es muy consistente entre folds. Con la diferencia crítica de Nemenyi (CD = 2.098 rangos) no se distinguen del mejor: Gradient Boosting, Random Forest; ese grupo es estadísticamente equivalente.

29. Diagrama de diferencia crítica



Cómo se lee. Cada punto es el rango medio de un modelo en los folds de validación cruzada. La banda verde se extiende desde el mejor modelo una distancia igual a la diferencia crítica de Nemenyi: los modelos dentro de la banda no son estadísticamente distinguibles del ganador.

Interpretación. Regresión Logística ocupa el mejor rango medio (1.00). Dentro de la banda (equivalentes al mejor): Random Forest, Gradient Boosting. Fuera de la banda (significativamente peores): Red Neuronal (MLP). Si varios modelos comparten banda, la elección entre ellos puede basarse en criterios secundarios como interpretabilidad o coste computacional.

30. Comparaciones por pares: Wilcoxon y t corregida de Nadeau-Bengio (Holm)

Modelo A	Modelo B	Δ F1 medio (A–B)	Wilcoxon p	t Nadeau-Bengio	p corregida N-B	r rango-biseri al	Wilcoxon p (Holm)
Regresión Logística	Gradient Boosting	0.0199	0.0625	3.547	0.0239	1	0.4375
Regresión Logística	Random Forest	0.0208	0.0625	3.152	0.0344	1	0.4375
Regresión Logística	Red Neuronal (MLP)	0.0689	0.0625	3.42	0.0268	1	0.4375
Gradient Boosting	Random Forest	0.0009	1	0.3372	0.7529	-0.0667	1
Gradient Boosting	Red Neuronal (MLP)	0.049	0.0625	2.501	0.0667	1	0.4375
Random Forest	Red Neuronal (MLP)	0.0481	0.0625	2.669	0.0559	1	0.4375
Regresión Logística	Línea base (azar estratificado)	0.7337	0.0625	29.23	0	1	0.4375

Modelo A	N-B p (Holm)	¿Diferencia significativa?
Regresión Logística	0.1432	No
Regresión Logística	0.1432	No


Modelo A	N-B p (Holm)	¿Diferencia significativa?
Regresión Logística	0.1432	No
Gradient Boosting	0.7529	No
Gradient Boosting	0.1677	No
Random Forest	0.1677	No
Regresión Logística	0.0001	Solo una prueba

Cómo se lee. Wilcoxon de rangos con signo: compara los F1 de dos modelos fold a fold (pareado, sin suponer normalidad). t corregida de Nadeau-Bengio (2003): corrige la varianza por el solapamiento entre conjuntos de entrenamiento de la CV, que hace que la t clásica tenga demasiados falsos positivos. Holm ajusta los p-valores por hacer muchas comparaciones. Se declara diferencia robusta solo si ambas pruebas la respaldan.

Interpretación. Se contrastan 7 pares con dos pruebas y corrección de Holm por comparaciones múltiples. Regresión Logística supera de forma robusta (ambas pruebas) a: ninguno. Frente a Gradient Boosting, Random Forest, Red Neuronal (MLP), Línea base (azar estratificado) la diferencia no es concluyente: la t corregida de Nadeau-Bengio es más conservadora que Wilcoxon porque tiene en cuenta que los folds comparten datos de entrenamiento. El r rango-biserial (−1 a 1) indica en qué proporción de folds gana A: $|r| > 0,5$ es un efecto grande.

VI. Despliegue (predicción e IA)


31. Predicción del escenario simulado



Cómo se lee. Probabilidad que el modelo seleccionado asigna a cada nivel de riesgo para el tract simulado. El nivel predicho es el de mayor probabilidad; la diferencia con el segundo indica la seguridad de la predicción.

Interpretación. El escenario se clasifica como MODERADO (12.4–18.2 % de Salud autorreportada regular o mala (%)) con probabilidad 75%; la segunda opción es Alto (25%). La decisión es clara.

32. Explicabilidad local: ¿qué determina esta predicción?



Variable	Valor escenario	Mediana	Efecto en P(nivel) (pp)
Sin seguro médico (%)	9.7	9.7	0
Inseguridad alimentaria (%)	17.9	17.9	0
Recibe ayuda alimentaria (SNAP) (%)	14.1	14.1	0
Inseguridad de vivienda (%)	14.7	14.7	0
Amenaza de corte de servicios (%)	7.9	7.9	0
Falta de transporte confiable (%)	8.7	8.7	0
Falta de apoyo social (%)	27.2	27.2	0
Soledad (%)	35.7	35.7	0
Chequeo médico anual (%)	78	78	0
Cribado de colesterol (%)	87.6	87.6	0
Tabaquismo (%)	10.7	10.7	0
Inactividad física (%)	22.6	22.6	0
Consumo excesivo de alcohol (%)	19	19	0

Cómo se lee. Para cada determinante se reemplaza su valor por la mediana del área (manteniendo el resto) y se mide cuánto cambia la probabilidad del nivel predicho. Rojo = la variable, en su valor actual, aumenta esa probabilidad; azul = la reduce. Es una explicación contrafactual local (tipo *ceteris paribus*).

Interpretación. Los factores con mayor efecto local son: «Sin seguro médico (%)» (+0.0 pp), «Inseguridad alimentaria (%)» (+0.0 pp), «Recibe ayuda alimentaria (SNAP) (%)» (+0.0 pp). Intervenir sobre los determinantes en rojo (acercarlos a la mediana) es lo que más reduciría la probabilidad de este nivel según el modelo; la relación es predictiva, no necesariamente causal.